

《数据采集与数据清洗》课程项目化考核作业

开题报告

题目	基于 Python 技术的淘宝笔记本电脑数据的采集与可视化分析				
专业	数据科学与大数据技术	年 级	2022 级	开题日期	2024. 5. 11
学 号	20220584009	姓 名	冒婷婷	指导教师	杨瑞梅
研究背景、研究目的与意义： 一、研究背景 随着互联网技术的快速发展和普及，大数据已成为现代社会的重要特征之一。在电子商务领域，尤其是像淘宝这样的电商平台，每天都会产生海量的交易数据。这些数据不仅记录了消费者的购物行为和偏好，也反映了商品的市场表现和竞争态势。笔记本电脑作为电子商务中销量较大的商品之一，其销售数据对于分析市场趋势、制定营销策略具有重要意义。因此，对淘宝笔记本电脑销售数据进行采集与可视化分析，不仅有助于商家更精准地把握市场需求，也为消费者提供了更为科学的购物参考。 二、研究目的 本研究旨在通过 Python 技术实现对淘宝笔记本电脑销售数据的采集，并利用可视化分析手段对数据进行深入挖掘，以期达到以下目的： （1）系统地收集淘宝平台上的笔记本电脑销售数据，建立全面的数据集； （2）对数据进行清洗和预处理，确保数据的准确性和可用性； （3）通过可视化分析，揭示笔记本电脑在淘宝平台上的销售规律，包括品牌的竞争态势、产地的分布特点以及价格与销量之间的关系； （4）为商家提供营销策略指导，同时也为消费者提供科学的购物参考。 三、研究意义 （1）学术价值：丰富了电商数据分析领域的研究内容，推动了数据分析技术在电商行业的更广泛应用和创新； （2）实践价值：为商家提供营销策略指导，有助于提升市场竞争力；					

- (3) 社会价值：提供科学的购物参考，有助于消费者做出更为理性的购物决策；
- (4) 技术价值：展示 Python 在大数据处理与分析中的应用潜力，推动了技术发展。

研究内容与进度安排：

一、研究内容

（一）数据采集

为了实现淘宝商品中笔记本电脑数据的自动化采集，可以利用 Python 编程语言结合 DrissionPage 自动化模块。

首先，我们需要配置如 csv、json 等必要的库。随后，我们将利用 DrissionPage 来模拟真实用户的浏览器行为，加载包含搜索关键词“笔记本电脑”的淘宝搜索页面。鉴于淘宝网站的数据加载方式可能包括异步加载或 API 请求，我们需要分析页面的网络请求，确定并捕获包含商品列表和详细信息的请求所返回的 JSON 格式数据。一旦我们捕获到这些 JSON 数据，就可以使用 Python 的 JSON 库解析。在解析过程中，我们将提取出标题、价格、产地、销量、店铺等关键的商品列表及详细信息字段。最后，我们将解析后的数据存储到本地 CSV 文件中，以便后续进行数据清洗和预处理。

（二）数据清洗与数据预处理

在该阶段，我们会对采集到的原始数据进行处理，以确保数据的准确性和可用性，为后续的数据分析提供高质量的数据源。首先，我们将去除数据采集过程中出现的重复信息，这些重复数据会干扰后续的数据分析。接着，我们会对关键字段进行格式化处理，将价格保留两位小数，销量字段转换为数字类型，以方便数据分析和比较。最后，针对数据中的缺失值进行删除或填补，从而确保数据的完整性和可靠性。

（三）数据分析

运用统计学和数据分析方法对清洗后的数据进行深入挖掘和分析。对笔记本电脑的品牌、产地、价格区间进行统计分析，了解不同品牌、产地和价格区间产品的销量占比和竞争态势。其次，研究笔记本电脑商品标题，揭示隐藏的消费者需求。最后，根据分析结果，为商家提供针对性的市场洞察和营销策略建议。主要分析内容包括：

（1）品牌分析：分析各品牌笔记本电脑的销量情况。

（2）产地分析：分析各产地笔记本电脑的销售数量，为厂商提供生产策略建议。

（3）类型分析：分析不同类型笔记本电脑的销量分布情况。

（4）价格区间分析：分析不同价格区间内商品数量与销量分布情况，了解消费者对不同价格区间商品的接受程度，为商家提供定价策略建议。

（5）商品标题分析：分析笔记本电脑市场的丰富多样性和消费者的多样化需求。

(四) 可视化展示 利用 Matplotlib 可视化工具，将分析结果以图表形式直观展示。通过可视化展示，使分析结果更加直观易懂，便于商家和消费者理解 and 应用。具体可视化内容包括： (1) 笔记本电脑销量 Top15 品牌柱状图：使用柱状图展示销量排名前 15 的笔记本电脑品牌，通过该图表，可以直观地了解哪些品牌在笔记本电脑销售方面具有较高的竞争力。 (2) 笔记本电脑产地 Top10 (地区/省份) 柱状图：利用饼图展示不同产地笔记本电脑的销售占比，帮助厂商了解各地区消费者的购买偏好和市场需求，从而优化生产布局和供应链管理。 (3) 不同笔记本电脑类型的销量分布饼图：通过饼图图呈现不同类型（轻薄本、游戏本、二合一笔记本）笔记本电脑的销量对比，为商家提供针对不同消费群体的产品策略建议。 (4) 不同价格区间的商品数量与销量分布：可以揭示笔记本电脑市场的价格分布规律，揭示消费者对价格敏感度的变化，指导商家制定更加合理的定价策略。 (5) 商品标题词云图：通过词云图展示笔记本电脑商品标题中的高频关键词，分析市场的热点话题和消费者关注的重点，为商家提供市场营销和广告推广的参考。 二、进度安排 阶段 1：2024 年 3 月 1 日-2024 年 4 月 1 日，查阅资料，收集资料，调研，确定课题； 阶段 2：2024 年 4 月 2 日-2024 年 5 月 11 日，确定方案，填写开题报告； 阶段 3：2024 年 5 月 12 日-2024 年 6 月 3 日，完成初稿； 阶段 4：2024 年 6 月 4 日-2024 年 6 月 10 日，定稿
拟采取的研究方法与可行性分析 1. 文献查找法：通过查阅相关领域的学术文献、研究报告等，了解电子商务数据分析和数据挖掘的研究现状和发展趋势，为本研究提供理论支持和参考依据。 2. 实验法：利用 Python 编写爬虫程序，从淘宝平台采集笔记本电脑相关数据；运用数据分析工具对数据进行预处理和分析；最后利用数据可视化工具将分析结果进行可视化展示。在实验过程中，将不断调整和优化爬虫程序、数据分析方法和可视化展示形式，确保研究结果的准确性和可靠性。

已完成的准备工作（含文献资料查阅与整理情况）

参考文献

- [1] 苗莉. 大数据分析在电商行业的运用实践之研究[J]. 营销界, 2020, (16):64-65.
- [2] 高雅婷, 刘雅举. 基于Python的网上购物数据爬取[J]. 现代信息科技, 2021, 5(16):26-31. DOI:10.19850/j.cnki.2096-4706.2021.16.007.
- [3] 薛晖. 一个企业销售数据管理与分析系统的设计与实现[D]. 东南大学, 2020. DOI:10.27014/d.cnki.gdnau.2020.003919.
- [4] 范路桥, 高洁, 段班祥, 等. 基于Python+ECharts的手机销售数据可视化系统[J]. 电脑编程技巧与维护, 2022, (06):78-81. DOI:10.16184/j.cnki.comprg.2022.06.046.
- [5] 汤飞弘. 基于Python爬虫的招聘信息数据可视化分析[J]. 软件, 2023, 44(01):176-179.
- [6] 王彦霞. 基于大数据技术的电商用户数据挖掘探讨[J]. 商场现代化, 2022, (23):58-60. DOI:10.14013/j.cnki.scxdh.2022.23.051.

指导教师意见:

指导教师（签名）:

学院意见:

学院（盖章）

____年____月____日