



重慶對外經貿學院
CHONGQING COLLEGE OF INTERNATIONAL BUSINESS AND ECONOMICS

《数据采集与数据清洗》课程 项目化考核作业

项目名称：基于 Python 技术的淘宝笔记本电脑

数据的采集与可视化分析

项目负责人：冒婷婷

项目负责人学号：20220584009

联系电话：13594261198

研究起止时间：2024.3.1-2024.6.10

填报日期：2024 年 6 月

大数据与智能工程学院 制

2024 年 6 月

维普论文检测-大学生版
作者：冒婷婷

总相似比：7.35%
检测字符数：4789

报告编号：9f51f6eb6f9tbc
检测时间：2024-06-29 16:18:36



基于Python技术的淘宝笔记本电脑数据的采集与可视化分析

【原文对照报告-大学生版】

报告编号：9f51f6eb6f9tbc
作者姓名：冒婷婷

检测时间：2024-06-29 16:18:36
所属单位：

检测字符数：4789

检测结论：全文总相似比 = 复写率 + 他引率 + 自引率 + 专业术语
7.35% = 5.33% + 2.02% + 0.0% + 0.0%

其他指标：自写率：92.65%

高频词：数据, 笔记本电脑, 销量, 商品, 市场

典型相似文章：无

疑似文字图片：0

指标说明：复写率：相似或疑似重复内容占全文的比重
自引率：引用自己已发表部分占全文的比重
典型相似性：相似或疑似重复内容占全文总相似比超过30%
他引率：引用他人的部分占全文的比重
自写率：原创内容占全文的比重
专业术语：公式定理、法律条文、行业用语等占全文的比重

相似片段：总相似片段 10
期刊：0 博硕：0 综合：0
外文：0 自建库：0 互联网：10

检测范围：中文科技期刊论文全文数据库
博士/硕士学位论文全文数据库
外文特色文献数据全库
高校自建资源库
个人自建资源库
中文主要报纸全文数据库
中国主要会议论文全文数据库
维普优先出版论文全文数据库
图书资源
年鉴资源
中国专利特色数据库
港澳台文献资源
互联网数据资源/互联网文档资源
古籍文献资源
IPUB原创作品

时间范围：1989-01-01至2024-06-29

基于 Python 技术的淘宝笔记本电脑数据的采集与可视化分析

冒婷婷

重庆对外经贸学院 大数据与智能工程学院 2022 级 数据科学与大数据技术 1 班

摘要：大数据时代背景下，笔记本电脑销售数据显著增长。通过采用 DrissionPage 自动化模块实现淘宝商品笔记本电脑数据的高效采集，利用 Python 技术进行数据处理并存储为 CSV 格式。通过 Matplotlib 进行数据可视化分析，深入研究销量领先的 15 大品牌、产地分布以及不同价格区间的商品数量与销量差异。通过揭示销售数据在地域与价格上的显著差异，可以为商家提供精确的市场洞察与营销策略指导，丰富了电商数据分析领域，同时展示 Python 在大数据处理与分析中的强大应用潜力。

关键词：Python；数据采集；可视化分析；淘宝；笔记本电脑

1 引言

在当今数字化的时代，笔记本电脑已成为人们工作、学习和生活中不可或缺的工具。随着电商行业的蓬勃发展，淘宝作为重要的电商平台，积累了海量的笔记本电脑销售数据。这些数据蕴含着丰富的信息，反映了市场的动态、消费者的需求和偏好。然而，要从这些繁杂的数据中提取有价值的洞察并非易事。

在此背景下，对淘宝笔记本电脑数据的采集与分析具有重要意义。通过运用先进的技术手段，我们能够系统地收集这些数据，并借助 Python 的强大功能进行深入挖掘和可视化呈现。了解笔记本电脑在淘宝平台上的销售情况，包括品牌的竞争态势、产地的分布特点以及价格与销量之间的关系，不仅能为消费者在选购时提供参考，也为企业制定精准的营销策略提供有力依据。

通过对淘宝笔记本电脑数据的全面采集和深入分析，我们期望揭示出隐藏在数据背后的规律和趋势，为电商领域的发展贡献一份力量，同时也进一步展现 Python 在处理和分析复杂数据方面的卓越能力，推动数据分析技术在电商行业的更广泛应用和创新^[1]。

2 数据爬取

2.1 初始化与监听设置

通过调用 `ChromiumPage()` 函数，创建了一个浏览器实例，该实例能够模拟真实的浏览器行为并控制其功能。为了捕获从淘宝服务器返回的商品数据，随后通过调用 `listen.start()` 方法设置了网络请求的监听，特别针对淘宝的 API 接口进行了监听设置。这一步骤确保了程序能够捕获到包含商品详细信息的服务器响应。在设置完监听后，利用浏览器对象的 `driver.get()` 方法，加载了包含搜索关键词“笔记本电脑”的淘宝搜索页面 URL，以便直接展示相关的商品搜索结果。整个流程涉及浏览器的初始化、网络请求的监听设置以及目标搜索页面的加载，为后续的数据提取和处理打下了基础。

2.2 监听解析与网络响应处理

在数据爬取过程中,当发起网络请求后,程序会调用 `listen.wait()` 方法等待监听的网络请求返回响应。一旦响应返回,程序将自动从响应的文本中提取出 JSON 格式的数据。随后,使用 `json.loads()` 方法将 JSON 字符串解析为 Python 可处理的数据结构,以便进行后续的数据处理和分析^[2]。为了确保数据爬取的稳定性,程序在提取和解析 JSON 数据时会进行周密的异常处理。如果在该过程中发生任何异常,如 JSON 数据提取失败或解析错误,程序将立即捕获这些异常并打印出相应的错误信息,从而帮助及时定位并解决问题。

2.3 数据解析与提取

在数据处理流程中,首先解析网络请求返回的数据,并成功提取出商品列表 `itemsArray`。随后,程序遍历商品列表,逐个提取商品的详细信息,包括标题、价格、产地(省份、城市)、销量以及店铺等关键信息。在提取过程中,数据清洗环节显得尤为重要。程序精心设计了去除标题中的 `span` 标签、处理销量数据中的非数字字符“人付款”等步骤,以确保数据的准确性和可用性。

2.4 反爬策略与突破

在进行淘宝商品数据爬取时,充分考虑到了可能遭遇的滑块验证等安全机制。为了应对这些挑战,设计了一个循环机制,持续监听网络响应,并不断尝试重新爬取数据。当发现商品列表为空时,会智能地判断这是否由安全验证所致,并继续循环监听。直到用户通过验证,服务器恢复数据响应为止。一旦获取到有效数据,会立即跳出循环,继续执行后续操作,如模拟翻页以获取更多页面数据。这种巧妙的设计不仅提高了爬虫的适应性和数据获取效率,也确保了在遭遇安全验证时,爬虫能够持续运行并最终成功爬取所需数据。

2.5 数据存储与格式化

在数据存储方面,选择了 CSV(逗号分隔值)格式。CSV 格式作为通用文件格式,以纯文本形式存储表格数据,使得数据能在不同系统和应用间轻松共享^[3]。它直观且易于阅读,对人类和机器都极为友好,方便进行解析和处理。考虑到需要遍历商品信息列表,并提取标题、价格、省份、城市、销量和店铺等关键信息,CSV 格式提供了一个结构化的方式来存储这些数据。每个商品的信息可以作为一个记录(row)存储在 CSV 文件中,而字段(如标题、价格等)则作为该记录的列(column)。在提取数据后,进行了必要的清洗和格式化步骤,如去除 `span` 标签、替换字符串等,以确保数据的准确性和一致性。这些清洗步骤对于后续的数据分析和处理至关重要。最后,使用 Python 的 CSV 模块轻松地将清洗后的数据写入 CSV 文件^[4]。`csv_writer.writerow` 方法能够将字典中的键值对作为一行数据写入^[5]。在此过程中,特别注意设置了正确的编码格式(UTF-8),以避免乱码问题的出现。

3 数据分析

3.1 可视化方法

淘宝笔记本电脑销售数据采集完毕后,随即展开了数据整理与分析工作。为了直观地展现数据中隐藏的信息,选择了具有卓越绘图能力的 Matplotlib 绘图库进行数据可视化。在可视化过程中,绘制了多个图表,包括展示销量 Top15 品牌和产地

Top10（省份/城市）的柱状图，基于商品标题的词云图，以及揭示不同价格区间商品数、销量以及笔记本电脑类型（游戏本、轻薄本、二合一笔记本）销量分布的饼图。这些精心设计的图表将数据中的信息以直观、易懂的形式展现出来，为后续的数据分析和市场研究提供了有力支持。

3.2 品牌分析

根据图 1，品牌联想的销售额最高，达到了 350000，凸显了其在市场中的领先地位。紧随其后的品牌例如华为、惠普，销售额也保持在较高水平，表明这些品牌在市场上同样具有较大的影响力。销售额逐渐递减的趋势展示了不同品牌之间的竞争态势，也反映了消费者对不同品牌的偏好和选择。尽管部分品牌的销售额相对较低，但它们仍然进入了 Top15 的行列，这表明了它们在特定消费者群体中的认可度和市场份额。总体来说，这张图清晰地展示了淘宝平台上笔记本电脑销量的分布情况，为消费者提供了购买时的参考依据，同时也为品牌方提供了市场分析和策略制定的参考。




图 1 笔记本电脑销量 Top15 品牌柱状图

3.3 产地分析




图 2 笔记本电脑产地 Top10（地区/省份）柱状图

分析图 2 发现，笔记本电脑的产量在不同地区或城市呈现出显著的差异。部分地区的产量高达数十万台，显示出它们在该领域的领先地位。这种差异可能源于资源、技术、劳动力以及市场需求的多样性。产量高的地区通常得益于其经济发展水平、优化的产业结构以及政府对高科技产业的积极扶持。这些地区通过提供税收优惠、资金支持和人才引进等激励措施，成功吸引了大量企业前来投资建厂，从而推动了笔记本电脑产业的繁荣发展。此图表还提醒观察者，在制定市场策略和发展规划时，应当充分考虑不同地区的市场需求和产业特点。

3.4 类型分析

从图 3 可以清晰地看到不同笔记本电脑类型在市场上的销量分布情况。游戏本占据的市场份额高达 68.2%，凸显了当前消费者对高性能游戏笔记本的强烈需求。紧随其后的是销量占比为 30.1%的轻薄本，深受需要频繁移动办公或出差的商务人士的喜爱。与游戏本和轻薄本相比，二合一笔记本的销量占比仅为 1.7%。由于其较高的定价和在某些功能上的局限性，使得一些消费者在购买时选择了其他类型的产品。这些信息对于笔记本电脑制造商和销售渠道商来说，具有重要的参考价值。

不同笔记本电脑类型的销量分布




图 3 不同笔记本电脑类型的销量分布饼图

3.5 价格区间分析




图 4 不同价格区间的商品数量与销量分布

图 4 详尽地呈现了笔记本电脑市场不同价格区间的商品数量及销量分布情况。价格区间在 3000-5000 元的笔记本电脑不仅商品数量最多，占比高达 46.4%，销量也占据市场主导地位，占比达到 39.0%，凸显了消费者对性价比高的中低端产品的

青睐。紧随其后的是 5000-7000 元的价格区间，商品数量与销量均表现出色。随着价格的提升，高端市场开始显现，但销量占比逐渐减少。20000 元以上的超高端笔记本电脑在市场上的销量极为有限，仅占 0.3%。综上所述，这张饼图清晰地揭示了笔记本电脑市场的价格分布规律，为笔记本电脑制造商提供了明确的市场定位和产品策略参考。

3.6 商品标题分析

图 5 这张笔记本电脑商品标题的词云图充分展示了笔记本电脑市场的丰富多样性和消费者的多样化需求。从图中可以看到，各个品牌以不同字体大小和颜色呈现，体现了不同品牌在市场上的重要性和消费者的关注度。在功能方面，“轻薄本”、“游戏本”、“商务”等词汇突出，反映了消费者对笔记本电脑在便携性、性能和用途上的不同追求。此外，“i5i7”、“大容量”、“触屏”等词汇也表明消费者在购买时还会关注具体的硬件配置和使用体验。通过这张图，可以更好地了解消费者的需求和市场的趋势。




图 5 商品标题词云图

4 总结

4.1 数据分析结果

本研究通过采集、清洗和可视化分析淘宝笔记本电脑销售数据，揭示了市场关键趋势。销量领先的 15 大品牌，特别是苹果、联想、戴尔等，占据市场主导地位，表明品牌效应显著。从产地分布看，中国大陆、台湾和美国为主要生产地，反映了全球制造业分布和消费者偏好。价格分析显示，高价位商品销量稳定，低价位竞争激烈，表明消费者对价格敏感且追求性价比。

4.2 研究意义与展望

本研究为商家提供了淘宝笔记本电脑市场的深刻洞察，助力其制定精准营销策略。商家可根据不同品牌和产地调整推广策略，针对不同价格区间提供更具性价比的产品。此外，本研究丰富了电商数据分析领域，展示了 Python 在大数据处理中的潜力，为其他领域研究提供启示。展望未来，随着大数据技术的发展，电商数据分析将成为企业核心竞争力^[6]。我们可进一步探索多维数据分析方法，拓宽研究领域，为商家提供更全面深入的市场洞察和决策支持。

参考文献：

[1] 苗莉. 大数据分析在电商行业的运用实践之研究[J]. 营销界, 2020, (16):64-65.

- [2] 高雅婷, 刘雅举. 基于Python的网上购物数据爬取[J]. 现代信息科技, 2021, 5(16):26-31. DOI:10.19850/j.cnki.2096-4706.2021.16.007.
- [3] 薛晖. 一个企业销售数据管理与分析系统的设计与实现[D]. 东南大学, 2020. DOI:10.27014/d.cnki.gdnau.2020.003919.
- [4] 范路桥, 高洁, 段班祥, 等. 基于Python+ECharts的手机销售数据可视化系统[J]. 电脑编程技巧与维护, 2022, (06):78-81. DOI:10.16184/j.cnki.comprg.2022.06.046.
- [5] 汤飞弘. 基于Python爬虫的招聘信息数据可视化分析[J]. 软件, 2023, 44(01):176-179.
- [6] 王彦霞. 基于大数据技术的电商用户数据挖掘探讨[J]. 商场现代化, 2022, (23):58-60. DOI:10.14013/j.cnki.scxdh.2022.23.051.